AI Engineering

Введение в LLM

https://linkedin.com/in/akrisanov

LLM глазами пользователя

ChatGPT 5.1

New chat
Search chats
Library
Codex
Atlas

GPTs
Explore
EnglishCap

Projects
Your chats

What can I help with?

Ask anything

Add photos & files
Add from Google Drive
Create image
Deep research
Shopping research
Agent mode
More
Study and learn
Web search
Canvas

Shop smarter this seas
Let ChatGPT do the digging for you, with in-depth research into the best deals and gifts.
Try it

Andrey Krisanov
Plus

deepseek

New chat

30 Days

DeepSeek AI Model Enhances Perfo

AI Answers User Questions on Testi

TestingCatalog: Website Testing Pla

My Profile

Hi, I'm DeepSeek.

How can I help you today?

Message DeepSeek

DeepThink

Search NEW

AI-generated, for reference only

New Chat

Agents

Intelligence Beta

New Project

Ask Le Chat anything

Research Think Tools

AK Andrey Krisanov
Le Chat Free

Upgrade to Pro

Get AI power in your browser with Comet Assistant Download →

Library
Discover
Spaces
Finance
More

perplexity

Ask anything. Type @ for mentions.

Fact Check | Finance | Health | Latest News | Shopping

Account
Upgrade
Install

Дисклеймер

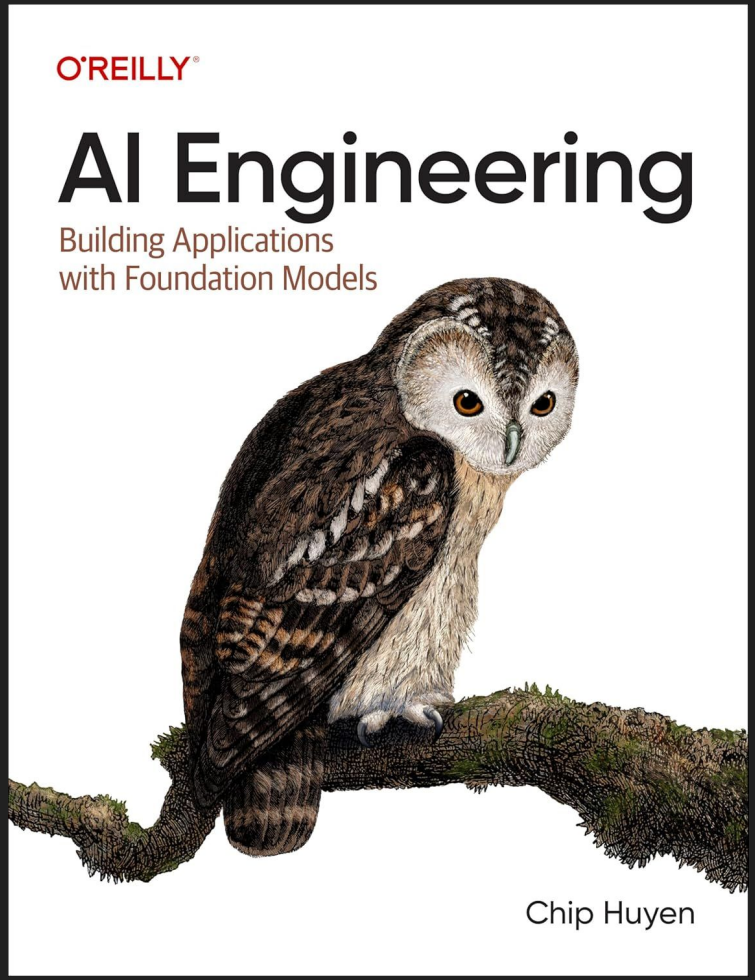

chiphuyen/**aie-book**

[WIP] Resources for AI engineers. Also contains supporting materials for the book AI Engineering (Chip Huyen, 2025)

5 Contributors | 10 Issues | 12k Stars | 2k Forks

https://github.com/chiphuyen

Смотря какой fabric
смотря сколько details

AI vs ML vs DL vs LLM

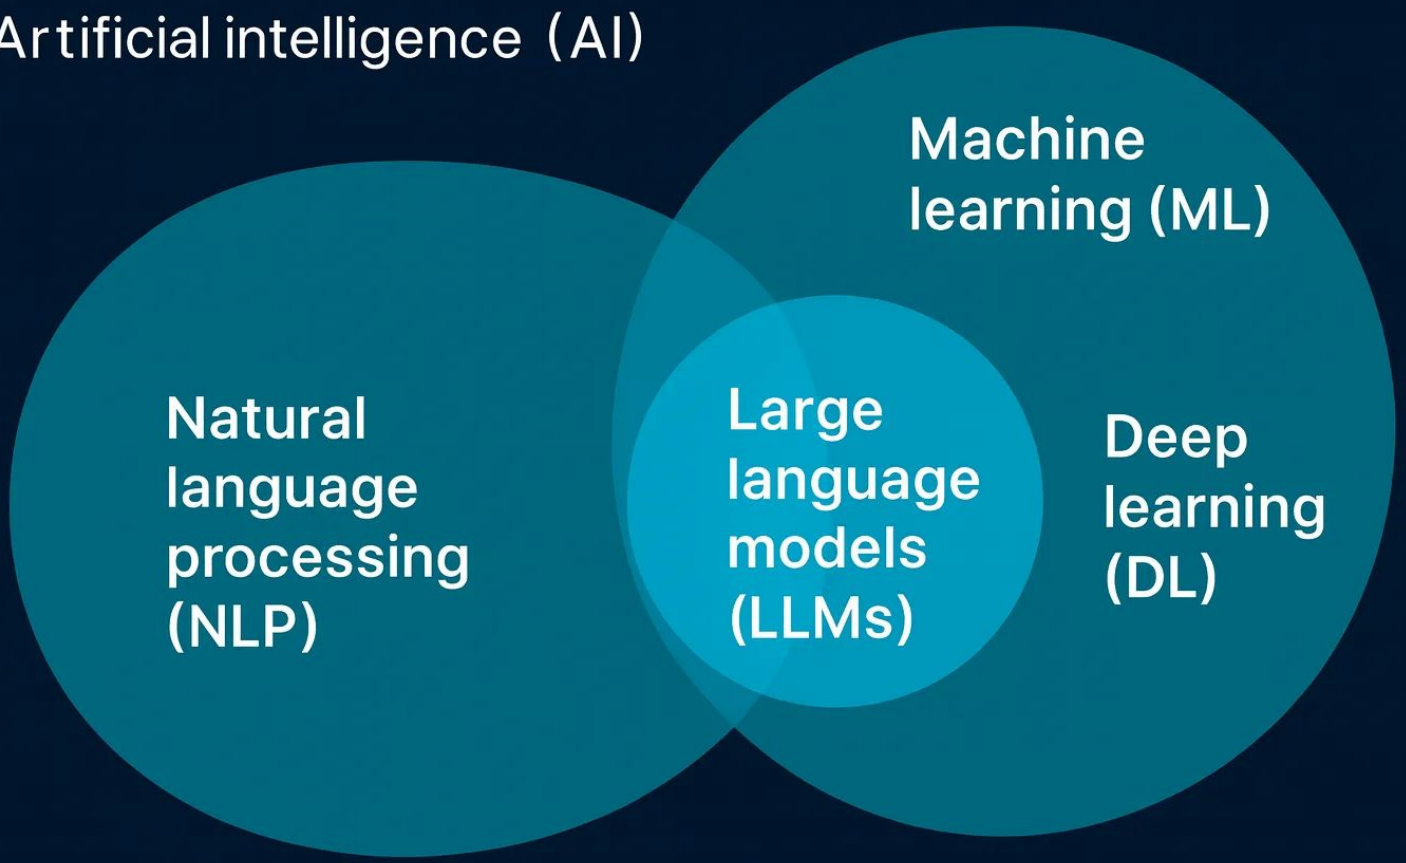
Artificial intelligence (AI)
Machine learning (ML)
Natural language processing (NLP)
Large language models (LLMs)
Deep learning (DL)

Что такое ML-модель?

Модель машинного обучения — это программа, которая сама учится находить закономерности в данных и использовать эти закономерности для прогнозов.

Например:

- Показываем модели тысячи фото котов → модель понимает «как выглядит кот»
- Потом даем новое фото → модель говорит: «это кот» или «не кот»

Что такое ML-модель?

1. **Структура (алгоритм)**. Например, нейросеть с миллиардами параметров.
2. **Параметры (веса)**. Это числа, которые модель подбирает в процессе обучения. Когда говорят «модель обучена», это значит параметры настроены.
3. **Процесс обучения**. Модель многократно сравнивает свои предсказания с правильными ответами и изменяет параметры, чтобы ошибаться меньше.
4. **Поведение после обучения**: классификация, предсказание значения, генерация текста, распознавание объекта на картинках и пр.

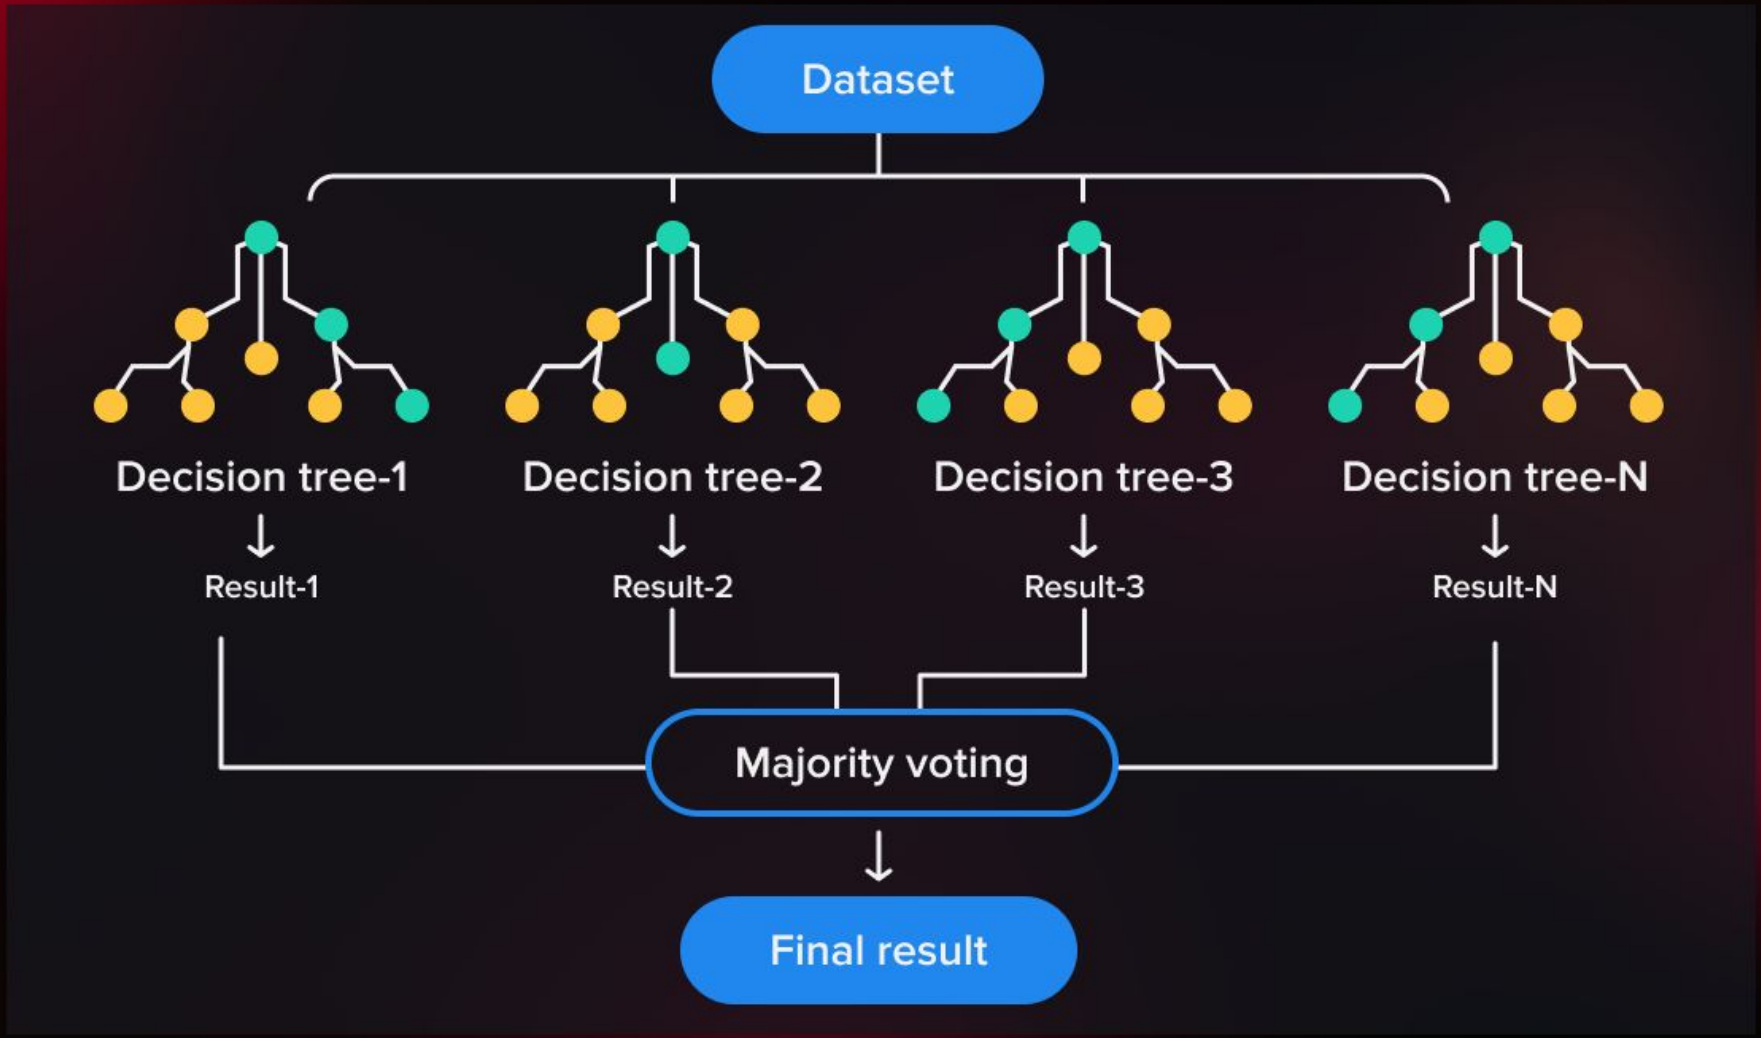
Dataset
Decision tree-1
Decision tree-2
Decision tree-3
Decision tree-N
Result-1
Result-2
Result-3
Result-N
Majority voting
Final result

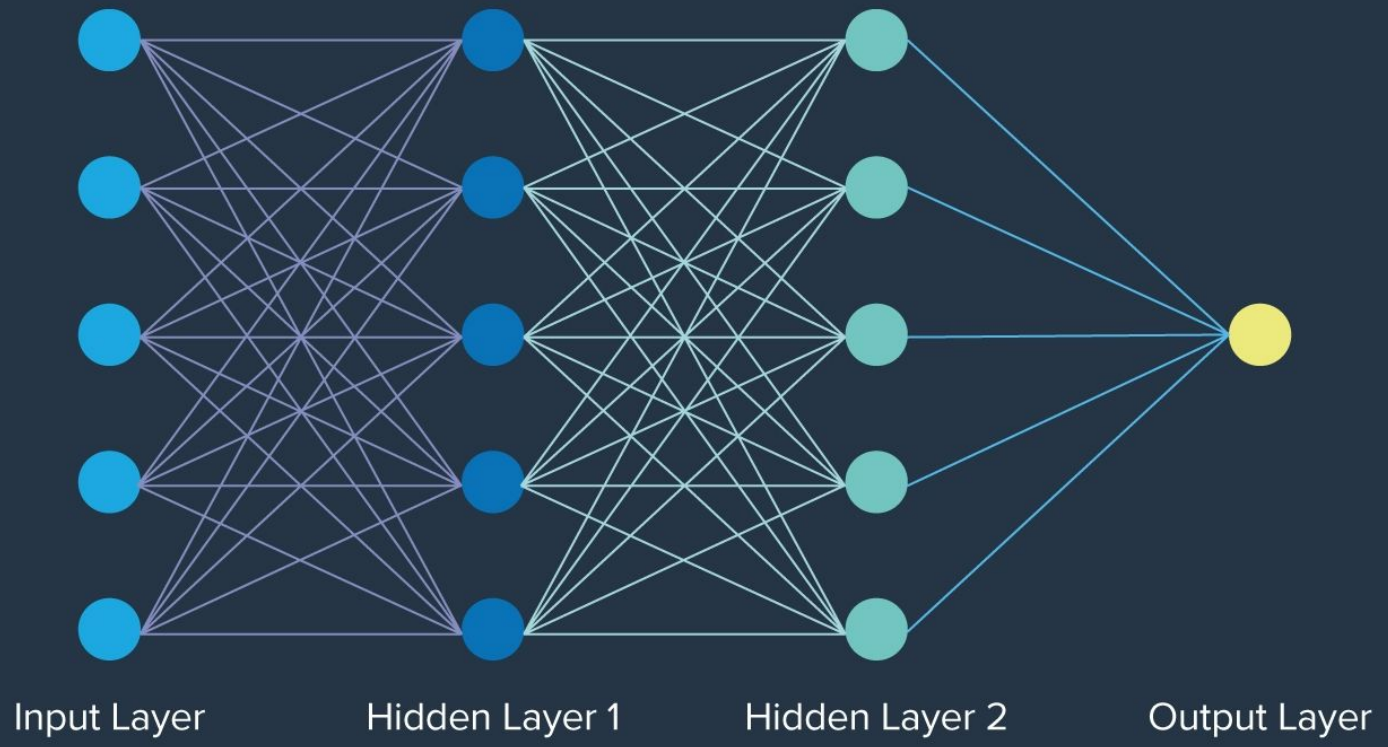
Input Layer
Hidden Layer 1
Hidden Layer 2
Output Layer

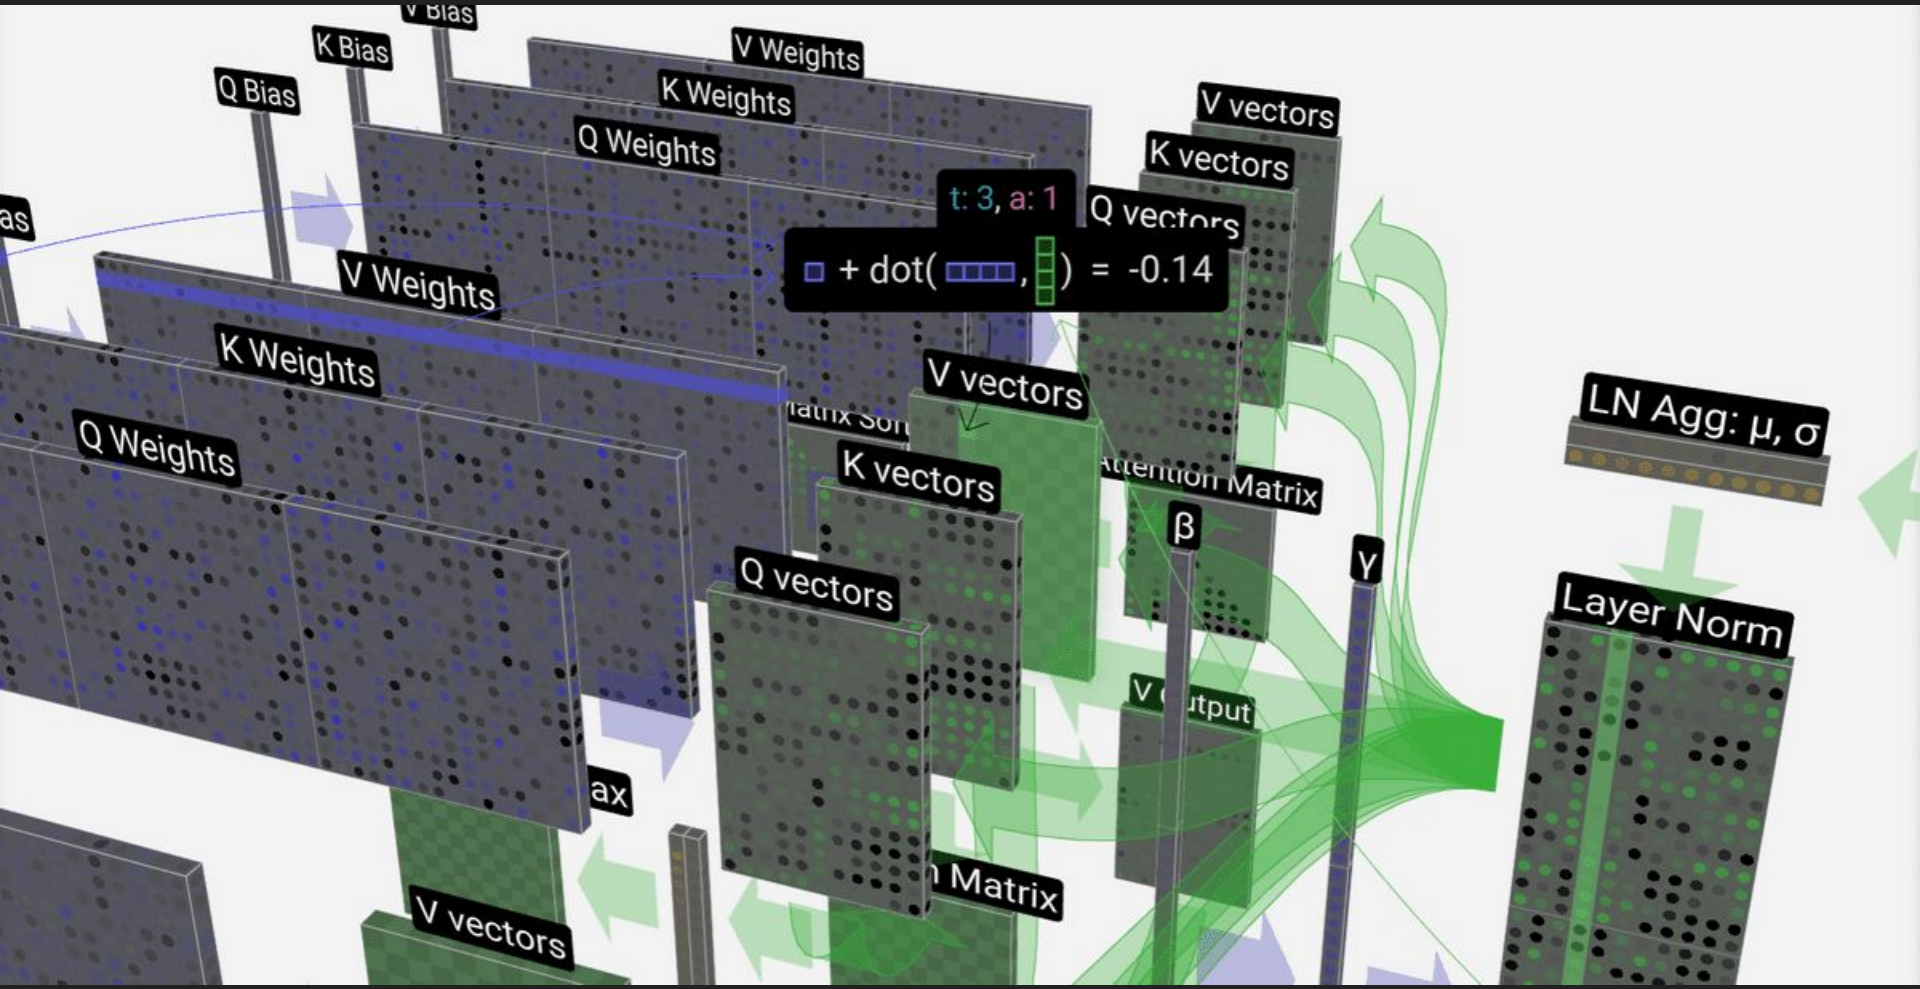
V Bias
K Bias
Q Bias
V Weights
K Weights
Q Weights
V vectors
K vectors
Q vectors
t: 3, a: 1
+ dot(,) = -0.14
V Weights
K Weights
Q Weights
V vectors
K vectors
Q vectors
Attention Matrix
β
γ
LN Agg: μ, σ
Layer Norm
V Output
V vectors

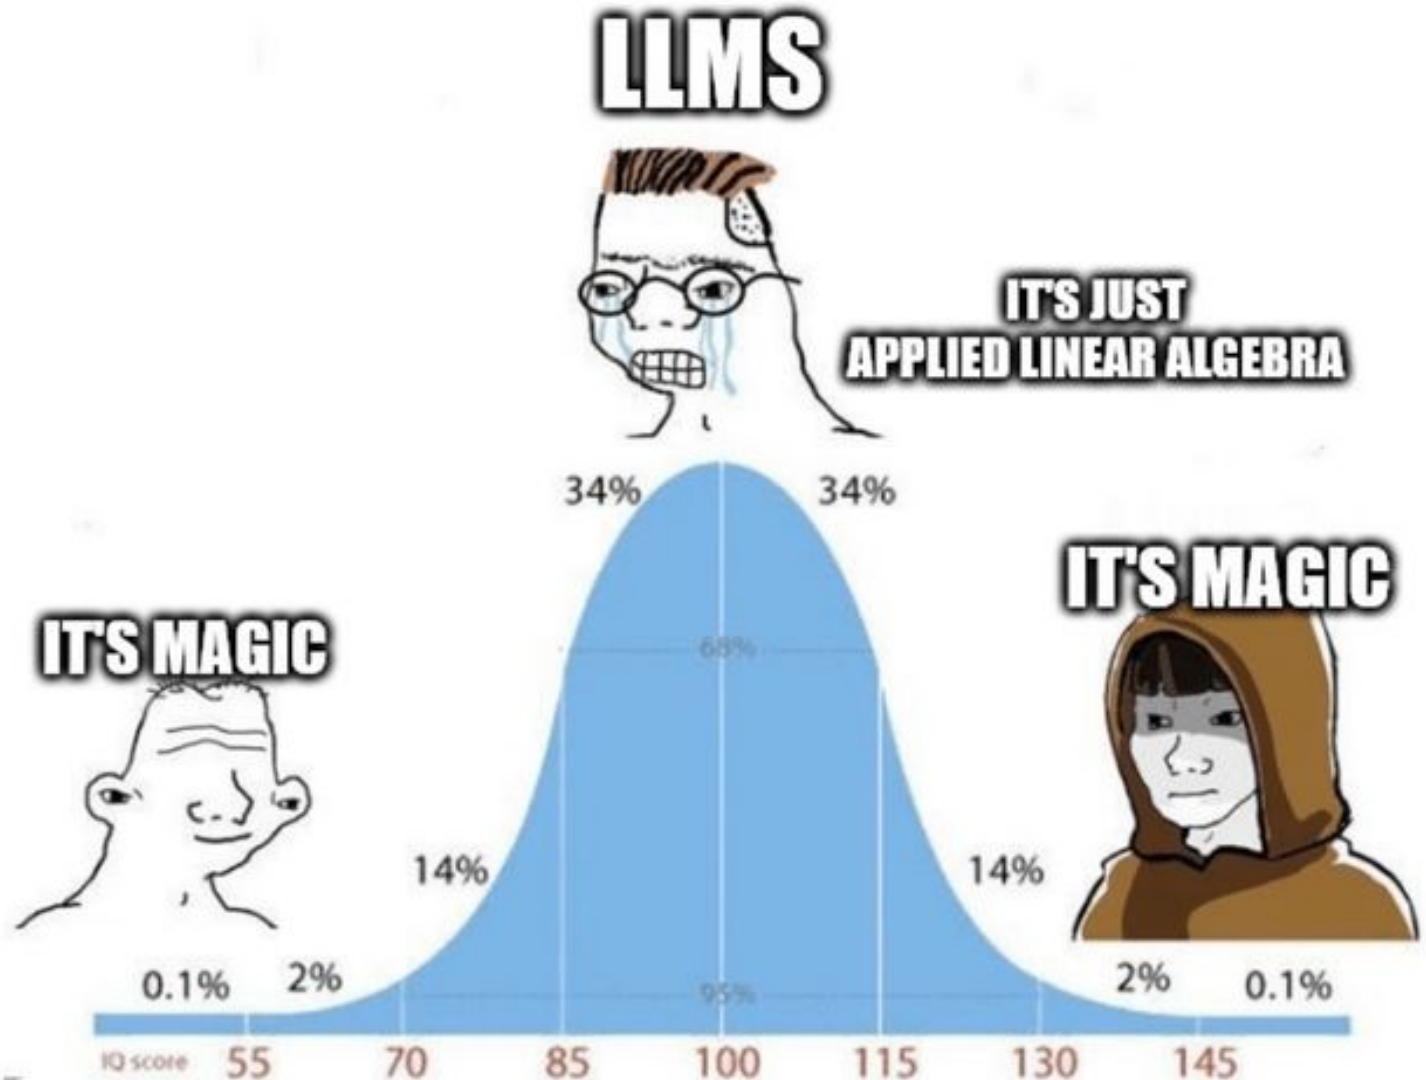
LLMS
IT'S JUST APPLIED LINEAR ALGEBRA
34%
34%
IT'S MAGIC
IT'S MAGIC
14%
14%
0.1%
2%
2%
0.1%
IQ score
55
70
85
100
115
130
145

AI Engineering

Что такое AI разработка в эпоху LLM

- В отличие от ML инженеров, которые создают модели с нуля, AI разработчики используют существующие для решения прикладных задач
- **Foundation модели** работают по принципу **self-supervision** (самоконтроля)
- Этот прорыв разрешил проблему маркировки данных, которая сдерживала развитие искусственного интеллекта в течение многих лет*
- По мере того как эти модели расширялись за счет увеличения объема данных и вычислительной мощности, они эволюционировали от простых языковых моделей до того, что мы сейчас называем **большими языковыми моделями** или **LLM**

- Сейчас LLM могут работать не только с текстом, но обрабатывать несколько другие типы данных, включая изображения, аудио и видео, т.е. являются **мультимодальными** LLM
- Применение LLM:
  - Универсальные chat-like ассистенты
  - Инструменты разработчика (GitHub Copilot, Cursor, Junie)
  - Windows Copilot и глубокая интеграция AI в ОС
  - Инструменты генерации изображений и видео
  - Боты для поддержки пользователей
  - Продвинутые инструменты аналитики данных
  - …
  - ∞

Foundation модели

- **Foundation модели** в своей основе знают только то, на чем они были обучены
- Если модель не видела примеров конкретного языка или концепции во время обучения, она просто не будет обладать релевантными знаниями
- Большинство LLM обучаются на данных, собранных с помощью веб-краулеров → *наследуемые проблемы*
- Эти данные часто содержат кликбейт, дезинформацию, токсичный контент и фейковые новости. Для борьбы с этим команды используют различные методы *фильтрации**.
- Распределение языков в обучающих данных также сильно смещено*
- Распределение доменов в тренировочных датасетах также может быть смещено в сторону *бизнеса*, *технологий*, *новостей* или *искусства*

Distribution of domains in the C4 dataset

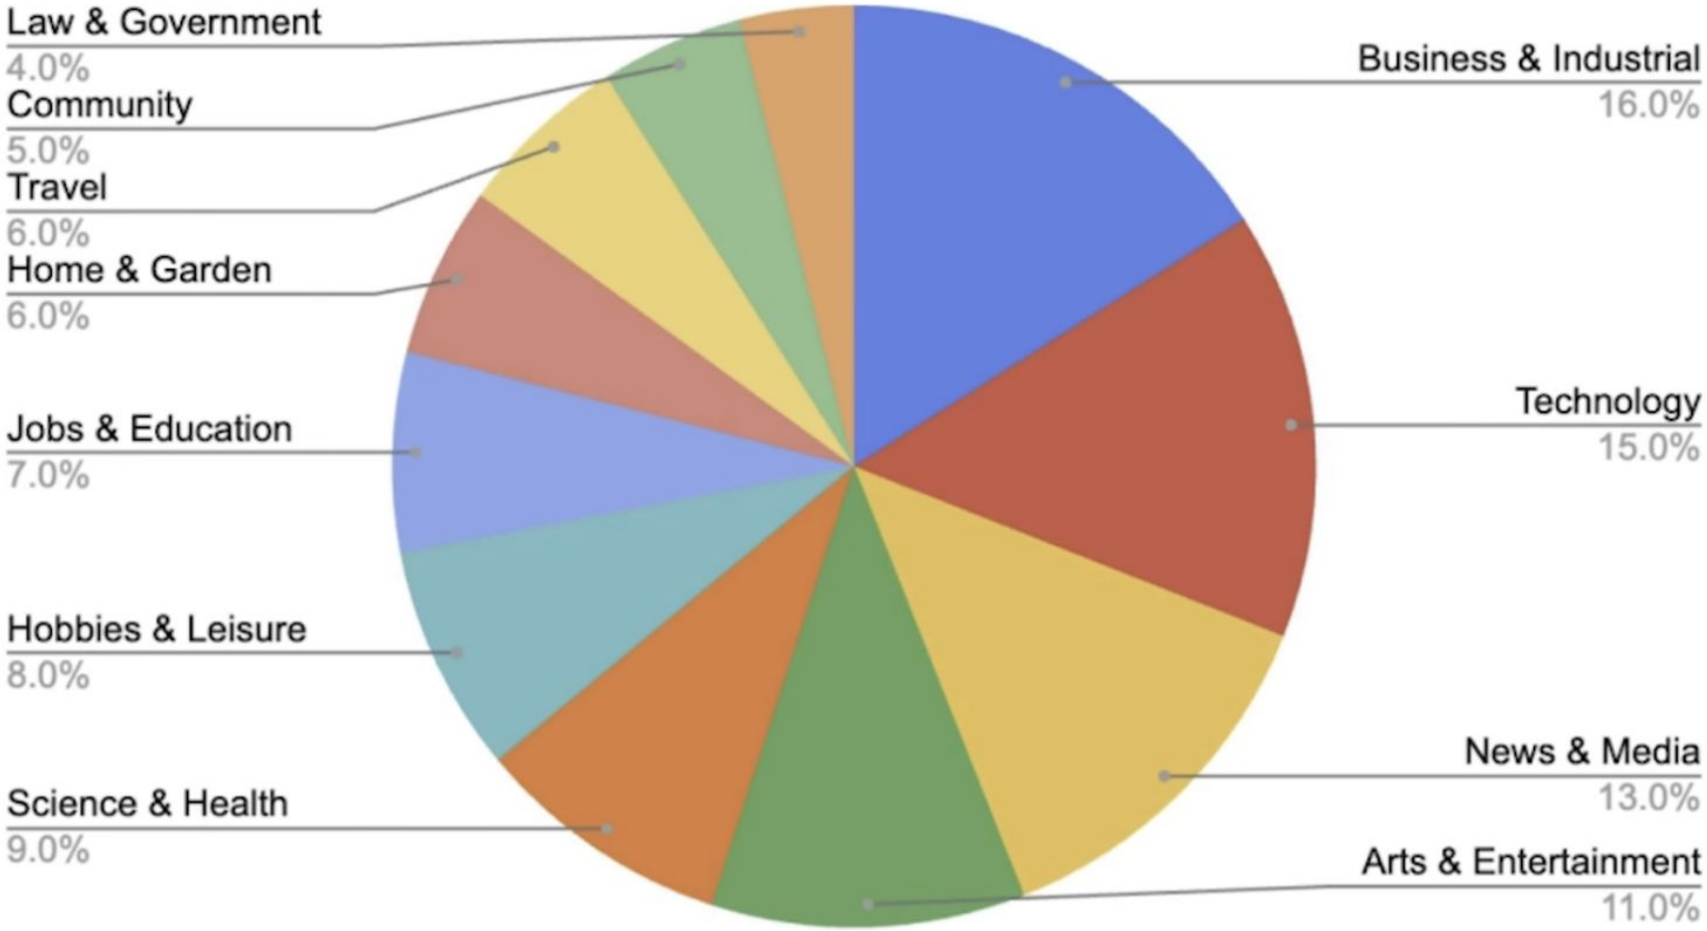

Архитектура трансформеров

- С точки зрения архитектуры, большинство foundation моделей имплементируют **архитектуру Transformer**, основанную на **attention-механизме**.
- Чтобы понять, почему трансформаторы стали таким прорывом, нам нужно взглянуть на то, что было до них.
- Изобретение трансформеров позволило решить проблемы **sequence-to-sequence** (seq2seq) моделей, таких как RNN для машинного перевода

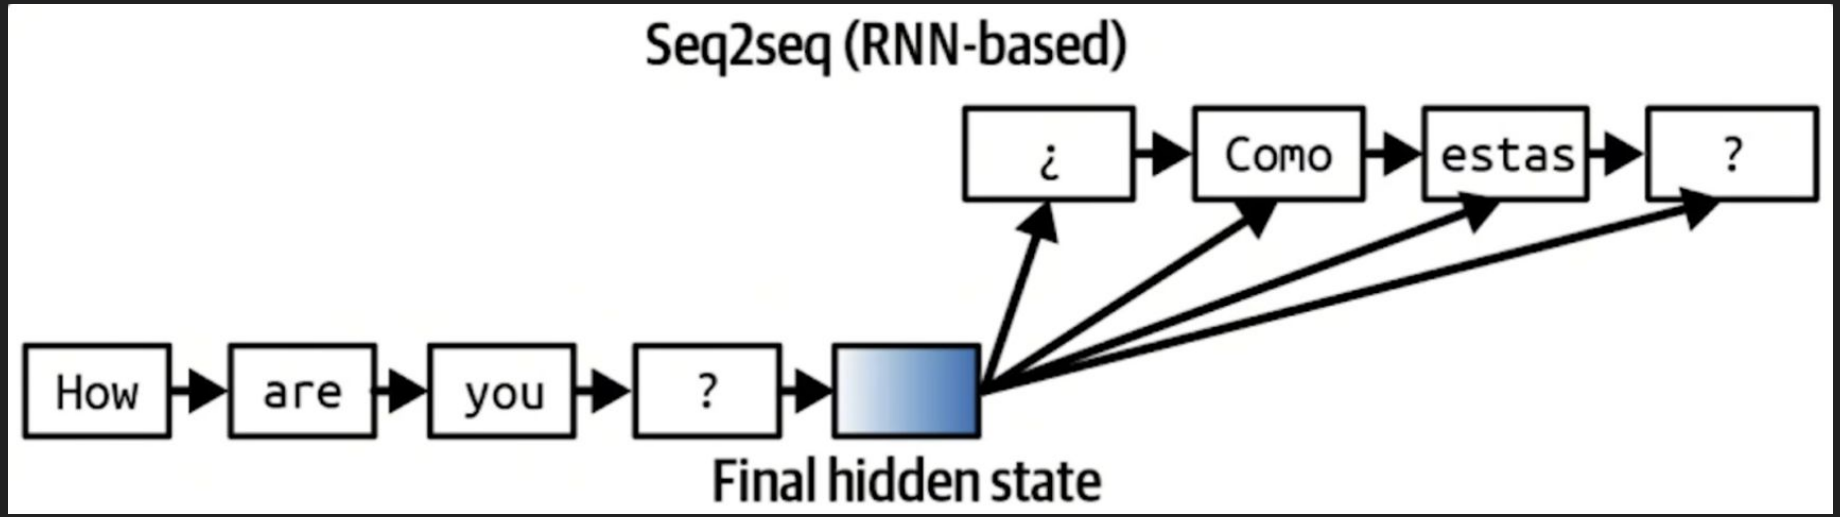

- 2 основных компонента: **encoder** и **decoder**
- Но оба работают последовательно – *токен* за токеном
- **Проблема**: декодер имеет доступ только к сжатому представлению всего входного сигнала*
- Обработка входных данных и генерация выходных данных выполняются последовательно → при длинных последовательностях процесс идет медленно

Токенизация и токены

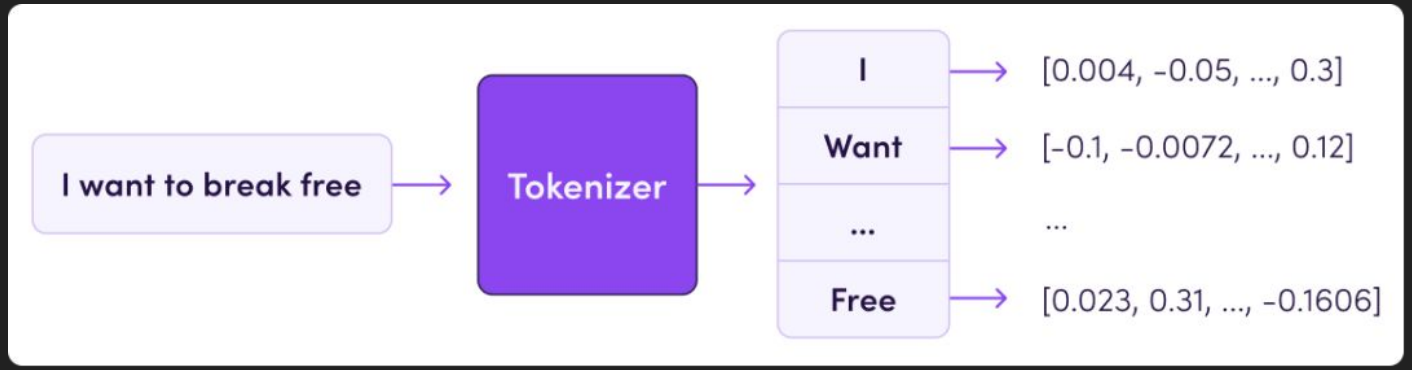

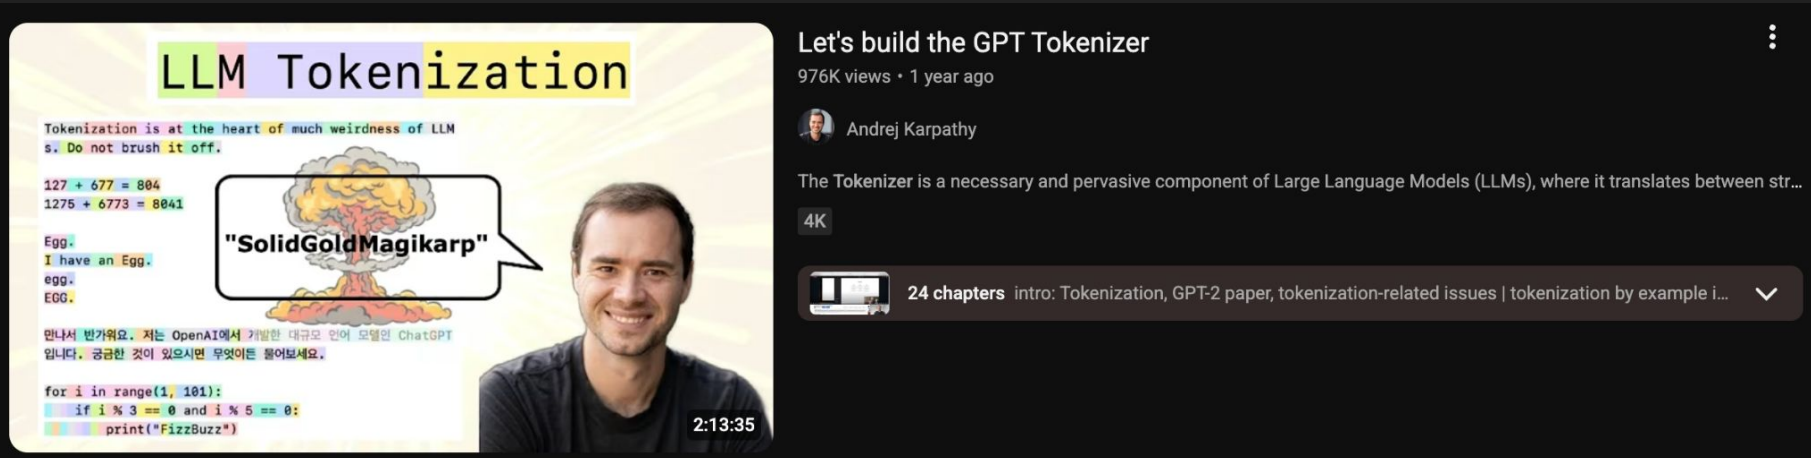

Tokens	Characters
64	252

Many words map to one token, but some don't: indivisible.

Unicode characters like emojis may be split into many toke
the underlying bytes: ******

Sequences of characters commonly found next to each other
together: 1234567890

TEXT TOKEN IDS

Attention-механизм

- В 2017 г. выходит paper от Google «Attention is all you need», BERT 👨🏼‍🔬
- Трансформеры решили эту проблему с помощью **механизма внимания**, который позволяет модели оценивать важность различных входных токенов при генерации каждого выходного токена*
- Также трансформеры позволили **параллельно** обрабатывать входные токеты, что существенно ускорило тренировку моделей

Transformer (attention mechanism)

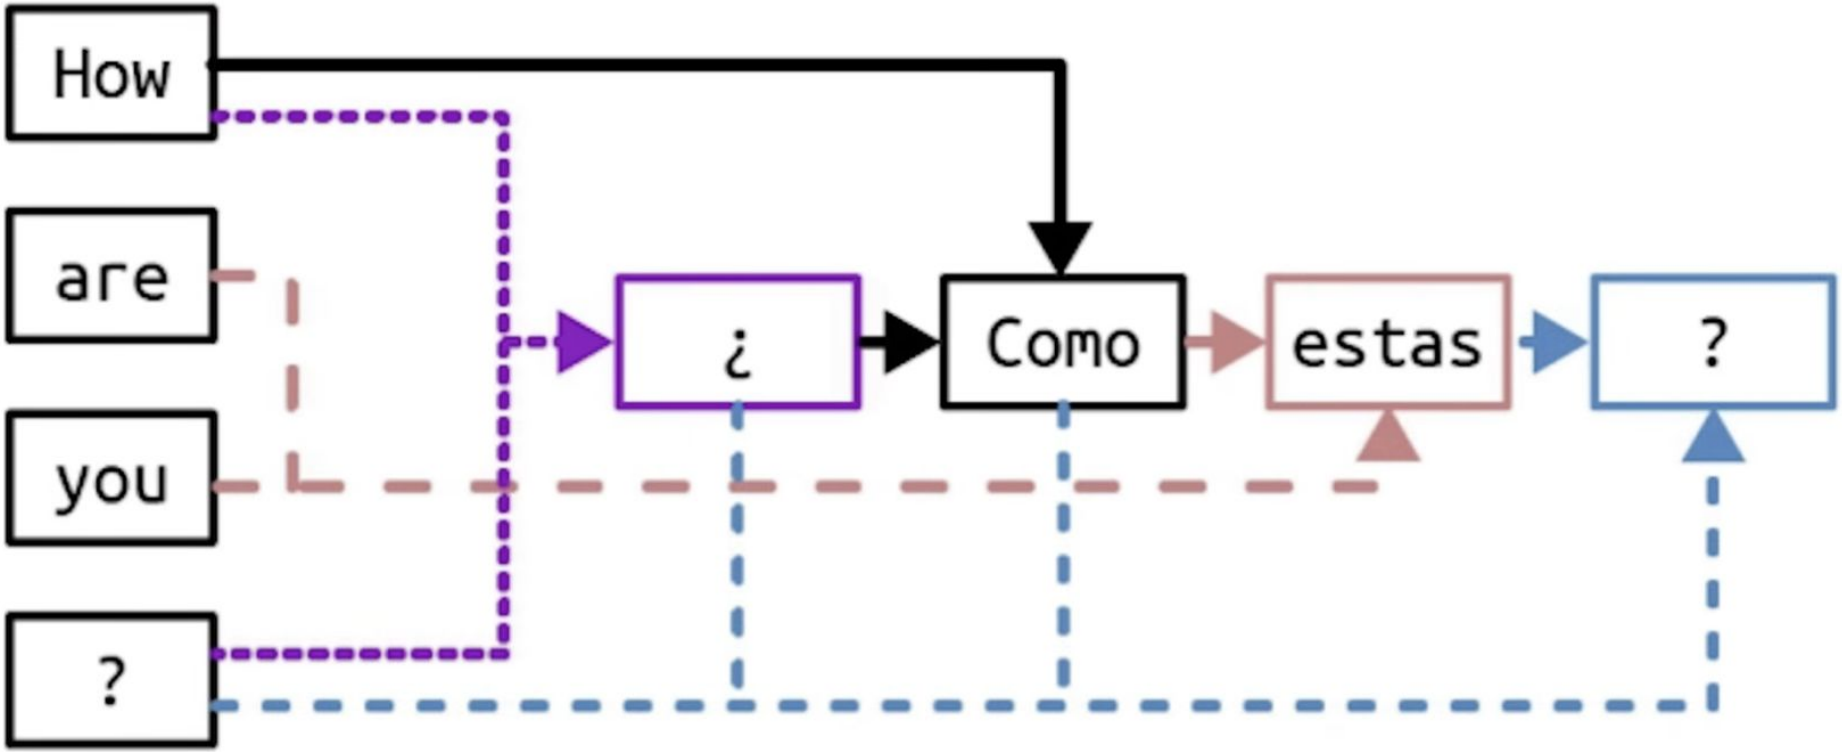

- Во время **инференса** трансформер работает в два этапа
  - **Prefill** (предварительное заполнение) → параллельная обработка всех *входных токенов* для создания промежуточного состояния
  - **Decode** (декодирование) → генерация *одного* выходного токена за раз
- **Attention-механизм** использует 3 типа векторов:
  - Векторы запросов (**Q**) – представляют информацию, которую ищет модель
  - Векторы ключей (**K**) – подобны индексам предыдущих токенов
  - Векторы значений (**V**) – фактическое содержание предыдущих векторов
- Модель вычисляет, сколько внимания следует уделить каждому токену, сравнивая векторы Q и K
- Высокий **similarity score** означает, что содержание токенов V будет сильно влиять на результат

более длинные **контекстные окна** требуют больших вычислительных затрат – больше токенов → больше векторов K и V, которые необходимо вычислять и хранить

Attention mechanism visualized from **Attention is all you need** (Vaswani et al., 2018)

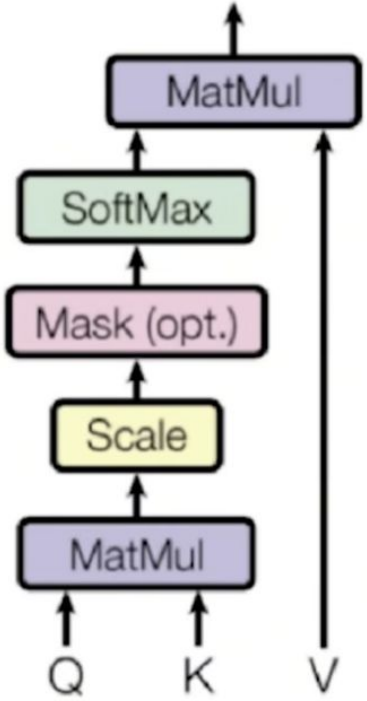

Attention mechanism in action: computing the next token from the previous tokens

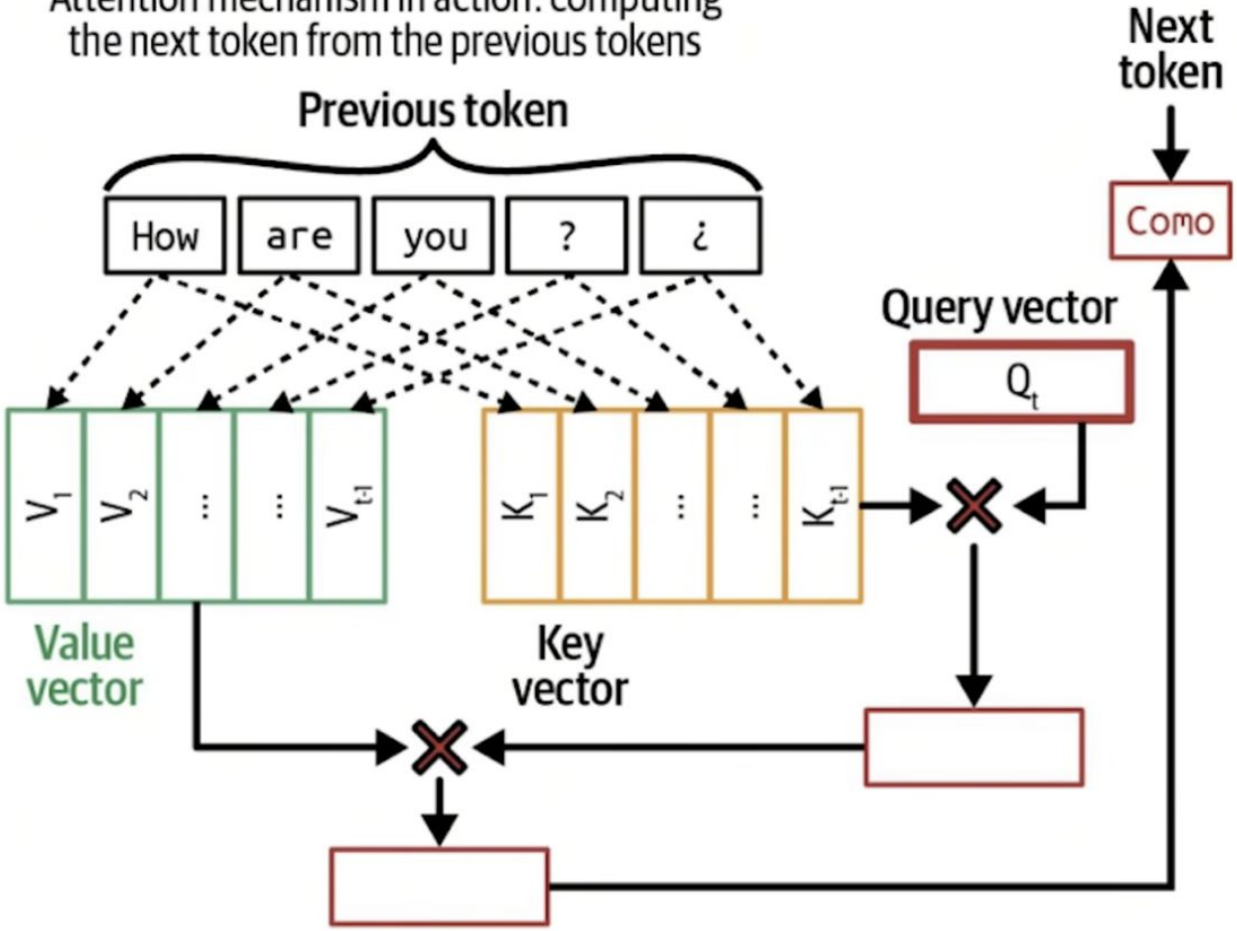

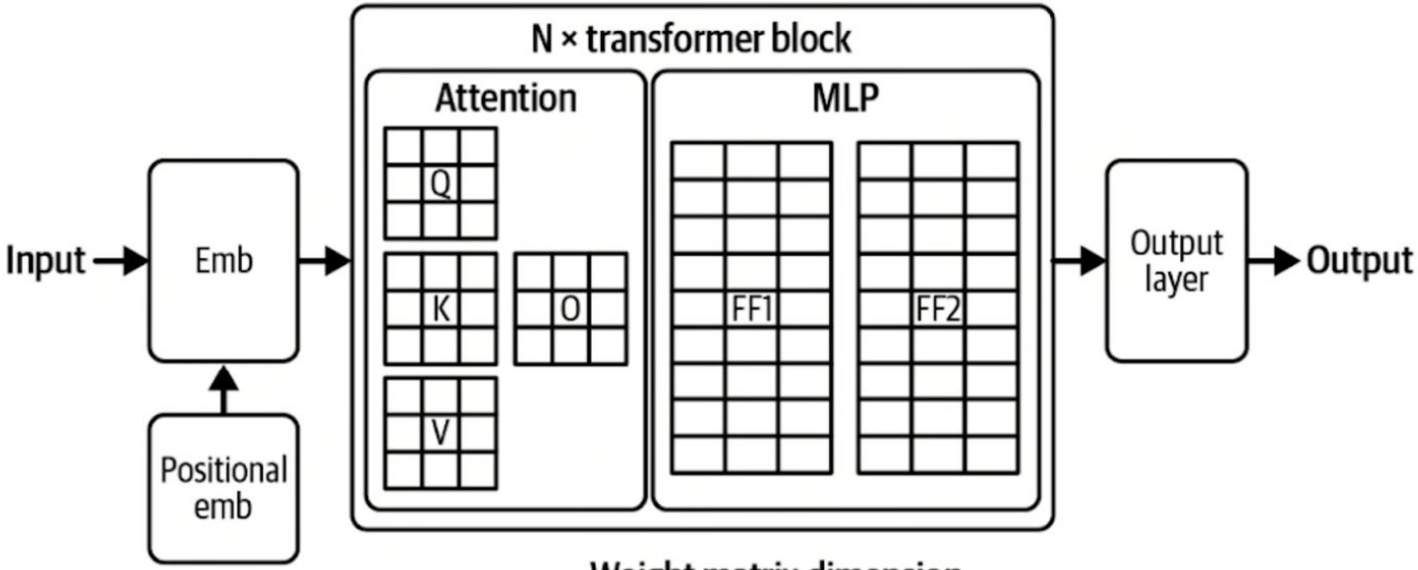

Weight matrix dimension

Q, K, V, O:	`d_model`	x	`d_model`
FF1:	`d_model`	x	`d_ff`
FF2:	`d_ff`	x	`d_model`
Embedding:	V	x	`d_model`
Positional emb:	C	x	`d_model`
Output:	`d_model`	x	V

with

`d_model`:	model's hidden size
`d_ff`:	feedforward dimension
V:	model's vocab size
C:	position indices to track

- Хотя трансформеры занимают доминирующее положение, они не являются единственной доступной архитектурой
- Модели типа RW KV, сочетающие подходы на основе RNN с возможностями параллелизации, набирают популярность для определенных приложений

Параметры модели

- В целом, модели с больш*и*м количеством параметров обладают большими возможностями для обучения и демонстрируют более высокую производительность
- Количество параметров помогает нам оценить вычислительные ресурсы, необходимые для обучения и инференса

Кол-во параметров может вводить в заблуждение в случае разреженных (sparse) моделей

- **Параметры модели** – это структура и количество обучаемых чисел в модели: веса + иногда смещения (bias).

  Когда говорят «модель на 7 млрд. параметров», имеют в виду:

  в ней примерно 7 миллиардов чисел, которые нужно хранить и умножать во время инференса

- При разработке модели вычислительные ресурсы часто являются ограничивающим фактором
- Chinchilla Scaling Law помогает рассчитать оптимальный размер модели и объем данных для заданного бюджета вычислительных ресурсов
- Количество токенов для обучения должно быть примерно *в 20 раз* больше размера модели, поэтому для модели с 3 млрд параметрами требуется около *60 млрд токенов*
- Хотя стоимость достижения *одной и той же же производительности* со временем снижается, **стоимость улучшений** (% ошибок) остается высокой – с 3% до 2% может потребоваться на порядок больше данных, вычислительных ресурсов или энергии*

Ограничения масштабирования LLM

- **Данные для обучения** – в ближайшие несколько лет мы можем исчерпать запас высококачественных интернет-данных, что вынудит модели обучаться на *синтетических данных* / контенте, сгенерированном AI → возможное снижение производительности или потребовать доступа к проприетарным данным (книги, защищенные авторским правом ресурсы, медицинские записи и пр.)
- **Электроэнергия** – центры обработки данных уже потребляют от 1 до 2 % мировой электроэнергии, что ограничивает возможности их дальнейшего роста без значительных прорывов в области энергетики

Проблемы пред-обученных моделей

- Оптимизированы для завершения / дополнения текста, а не для ведения диалога
- Результаты LLM могут быть фактически неверными или этически проблематичными

How people from non-tech background see LLM generated code

How senior developers see LLM generated code

Пост-обучение моделей

- **Supervised fine-tuning (SFT)** – оптимизируем модель для ведения диалогов, а не для дополнения текста.*
- **Preference fine-tuning** – согласовываем модель с человеческими ценностями с помощью RL (обучения с подкреплением) / **RLHF** (обучение с подкреплением на основе обратной связи от человека)*
- Хотя RLHF остается стандартным способом, новые методы (direct preference optimization (*DPO*)) набирают обороты*

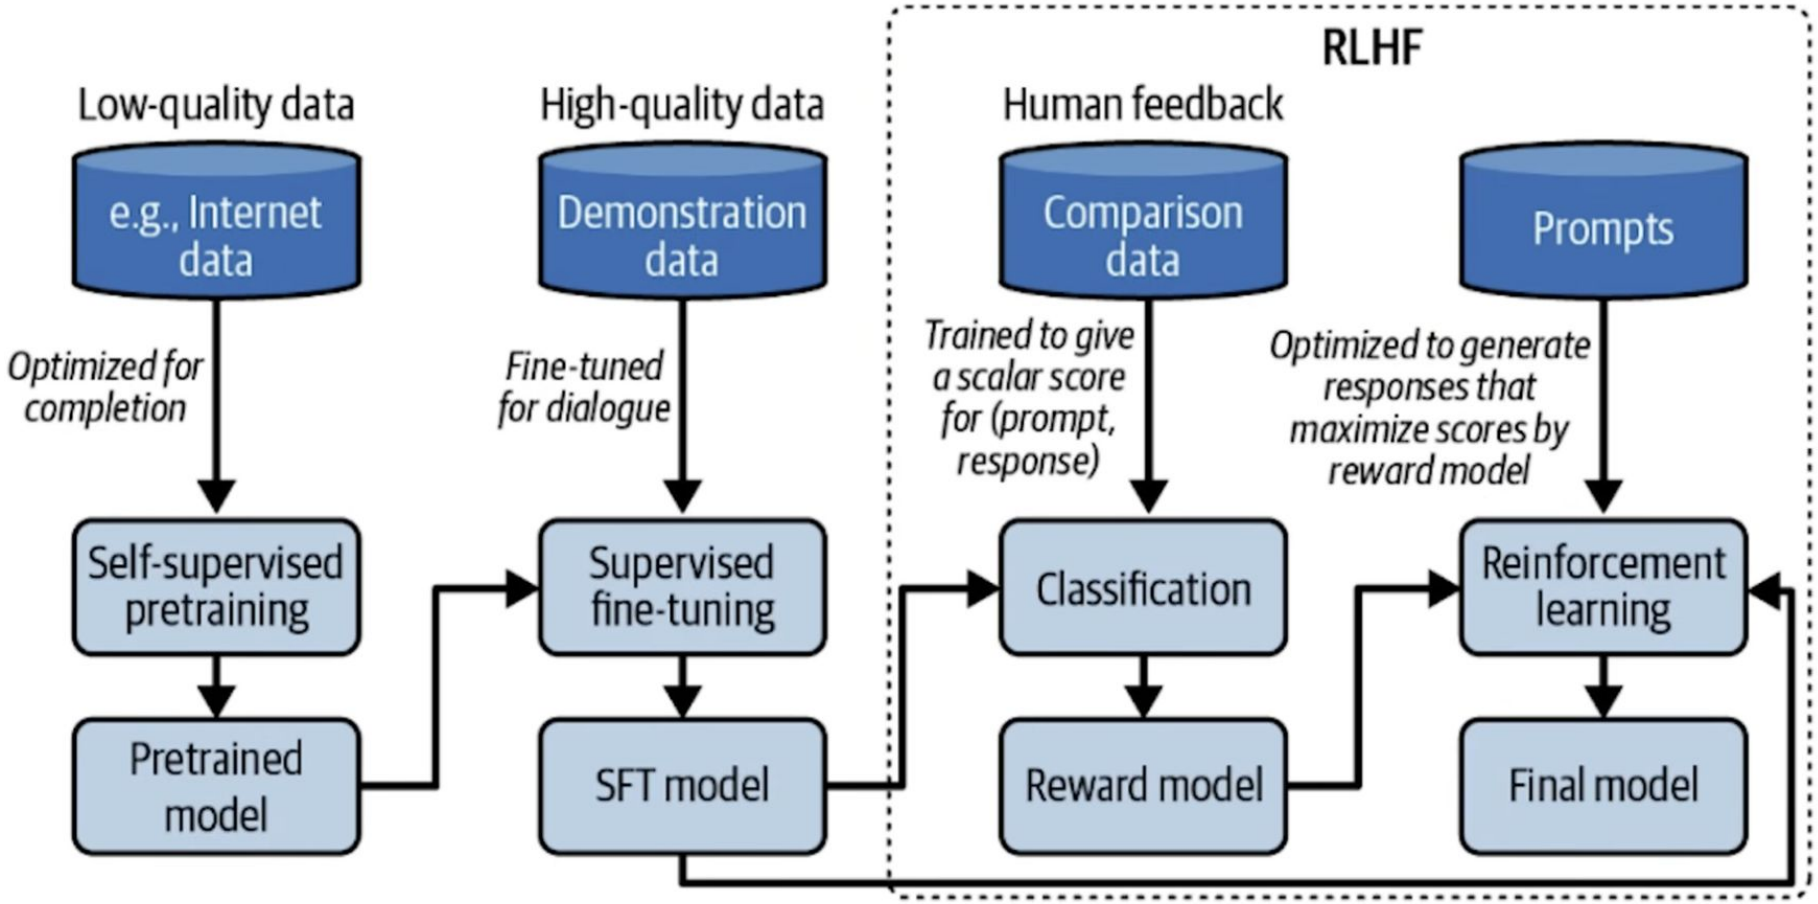
RLHF
Low-quality data
High-quality data
Human feedback
e.g., Internet data
Demonstration data
Comparison data
Prompts
Optimized for completion
Fine-tuned for dialogue
Trained to give a scalar score for (prompt, response)
Optimized to generate responses that maximize scores by reward model
Self-supervised pretraining
Supervised fine-tuning
Classification
Reinforcement learning
Pretrained model
SFT model
Reward model
Final model

Вероятности возможных ответов

- Foundation модели не дают единственного окончательного ответа, они **генерируют вероятности возможных результатов**
- То, как мы отбираем образцы (*sampling*) из этих вероятностей, существенно влияет на качество ответов модели
- Самый простой вариант – **greedy sampling** → всегда выбираем токен с самой большой вероятностью. Минус – всегда приводит к повторяющемуся и предсказуемому тексту
- Нам нужна креативность! С этим нам помогает коэффициент случайности **temperature** 🌡️
  - t = 0.0-0.2 → максимально детерминировано
  - t = 0.7-1.0 → разнообразнее
  - t > 1.2 → хаотично и творчески

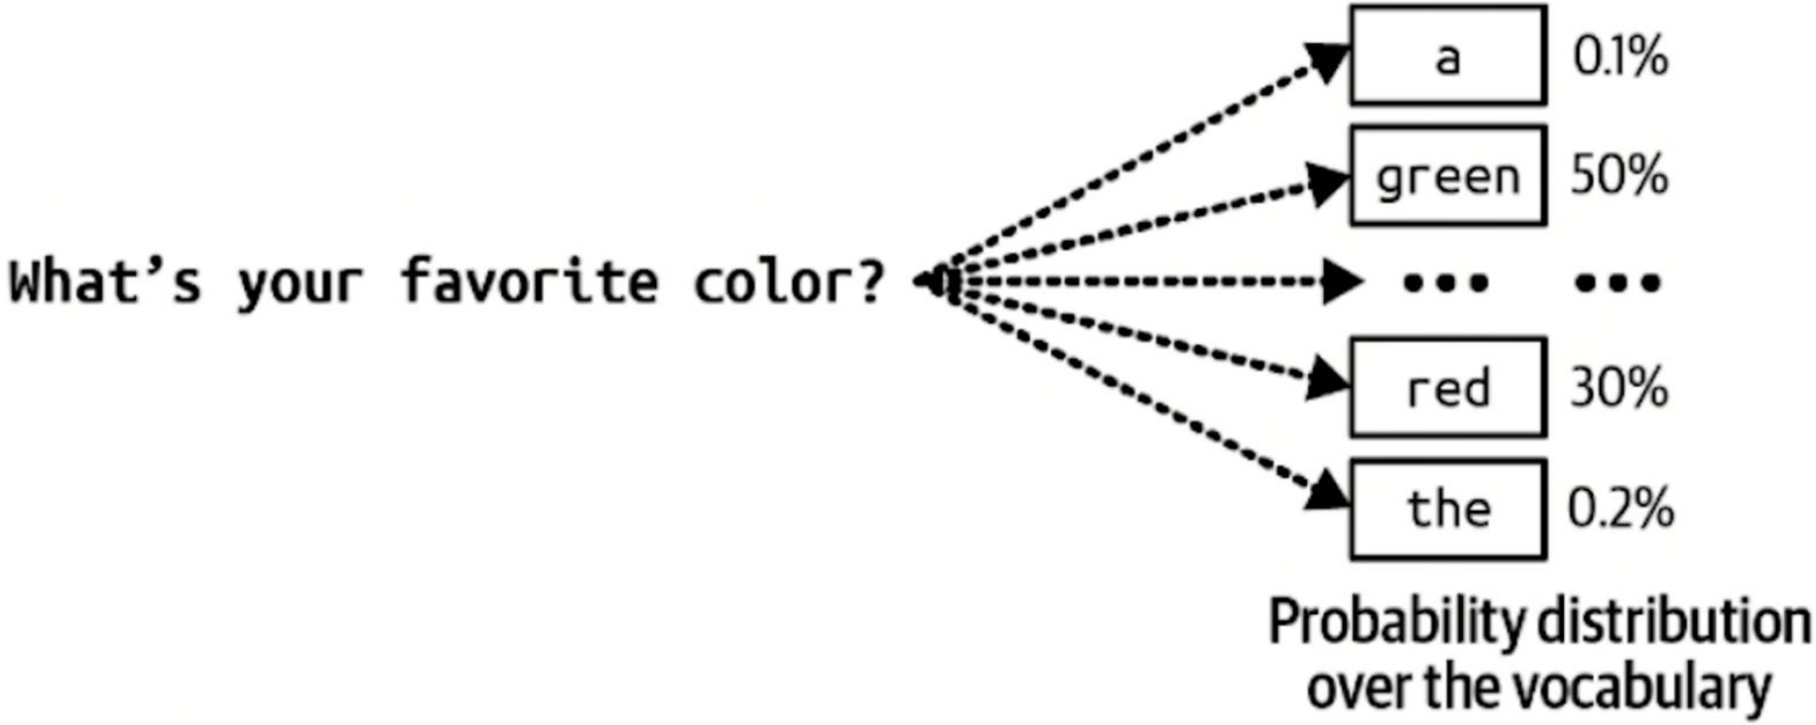
What's your favorite color?
a
0.1%
green
50%
...
...
red
30%
the
0.2%
Probability distribution over the vocabulary

Другие техники замплинга

- **Top-k выборка** ограничивает модель выбором только из **k** наиболее вероятных следующих токенов (обычно от 50 до 500 – в зависимости от того, насколько разнообразными мы хотим видеть ответы)
- **Top-p выборка** (или nucleus) выбирает *наименьший набор токенов*, чья совокупная вероятность превышает пороговое значение **p***

Эта вероятностная природа объясняет многие из поведений, которые мы наблюдаем в foundation моделях:

- несоответствие при незначительных изменениях входных данных
- галлюцинации (с уверенностью заявляют неверную информацию)